

# Robótica Móvil un enfoque probabilístico

## **Robótica Probabilística**

Ignacio Mas

---

# Robótica Probabilística

## Idea principal:

### **Representación explícita de la incertidumbre**

(usando la teoría del cálculo de probabilidades)

- Percepción = estimación de estado
- Acción = optimización de utilidad

# Axiomas de la Probabilidad

$P(A)$  indica la probabilidad de que la proposición  $A$  es verdadera.


- $0 \leq P(A) \leq 1$

- $P(\textit{True}) = 1$                        $P(\textit{False}) = 0$

- $P(A \vee B) = P(A) + P(B) - P(A \wedge B)$

# Detalles del Axioma 3

$$P(A \vee B) = P(A) + P(B) - P(A \wedge B)$$



# Usando los Axiomas

$$P(A \vee \neg A) = P(A) + P(\neg A) - P(A \wedge \neg A)$$

$$P(\textit{True}) = P(A) + P(\neg A) - P(\textit{False})$$

$$1 = P(A) + P(\neg A) - 0$$

$$P(\neg A) = 1 - P(A)$$

# Variables aleatorias discretas

- $X$  denota una **variable aleatoria**
- $X$  puede tomar un número contable de valores en  $\{x_1, x_2, \dots, x_n\}$
- $P(X=x_i)$  o  $P(x_i)$  es la **probabilidad** que la variable aleatoria  $X$  tome el valor  $x_i$
- $P(\cdot)$  es la **función de masa de probabilidad**
- Ejemplo:


$$P(\text{habitación}) = \langle 0.7, 0.2, 0.08, 0.02 \rangle$$

# Variables aleatorias continuas

- $X$  toma valores en un continuo.
- $p(X=x)$  o  $p(x)$  es una **función de densidad de probabilidad**

$$P(x \in [a, b]) = \int_a^b p(x) dx$$

- Ejemplo:



# Las probabilidades suman 1

**Caso Discreto**

$$\sum_x P(x) = 1$$

**Caso Continuo**

$$\int p(x)dx = 1$$



# Probabilidad conjunta y condicional

- $P(X=x \text{ e } Y=y) = P(x,y)$
- Si  $X$  e  $Y$  son **independientes** entonces
$$P(x,y) = P(x) P(y)$$
- $P(x / y)$  es la probabilidad de  **$x$  dado  $y$** 
$$P(x / y) = P(x,y) / P(y)$$
$$P(x,y) = P(x / y) P(y)$$
- Si  $X$  e  $Y$  son **independientes** entonces
$$P(x / y) = P(x)$$

# Ley de la Probabilidad Total

**Caso discreto**

$$P(x) = \sum_y P(x | y) P(y)$$

**Caso continuo**

$$p(x) = \int p(x | y) p(y) dy$$

# Marginalización

## Caso Discreto

$$P(x) = \sum_y P(x, y)$$

## Caso continuo

$$p(x) = \int p(x, y) dy$$

# Fórmula de Bayes

$$P(x, y) = P(x | y)P(y) = P(y | x)P(x)$$

$\Rightarrow$

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)} = \frac{\text{likelihood} \cdot \text{prior}}{\text{evidence}}$$

# Normalización

$$P(x|y) = \frac{P(y|x)P(x)}{P(y)} = \eta P(y|x)P(x)$$

$$\eta = P(y)^{-1} = \frac{1}{\sum_x P(y|x)P(x)}$$

## Algoritmo:

$$\forall x : \text{aux}_{x|y} = P(y|x)P(x)$$

$$\eta = \frac{1}{\sum_x \text{aux}_{x|y}}$$

$$\forall x : P(x|y) = \eta \text{aux}_{x|y}$$

# Regla de Bayes con conocimiento de fondo (Background Knowledge)

$$P(x | y, z) = \frac{P(y | x, z) P(x | z)}{P(y | z)}$$

# Independencia Condicional

$$P(x, y | z) = P(x | z)P(y | z)$$

- Equivalente a  $P(x | z) = P(x | z, y)$

y  $P(y | z) = P(y | z, x)$


- Pero esto no necesariamente indica que

$$P(x, y) = P(x)P(y)$$

(independencia/independencia marginal)

# Ejemplo simple de estimación de estado

- Supongamos que el robot obtiene la medición  $z$
- Cuál es el valor de  $P(\text{abierta} / z)$ ?






# Causal vs. razonamiento diagnóstico

- $P(\text{abierta}/z)$  es un diagnóstico
- $P(z/\text{abierta})$  es información causal
- Muchas veces, el conocimiento causal es más fácil de obtener **contar frecuencias!**
- Bayes permite usar información causal:

$$P(\text{abierta} | z) = \frac{P(z | \text{abierta})P(\text{abierta})}{P(z)}$$

# Ejemplo



- $P(z/abierta) = 0.6$                        $P(z/\neg abierta) = 0.3$
- $P(abierta) = P(\neg abierta) = 0.5$

$$P(abierta | z) = \frac{P(z | abierta)P(abierta)}{P(z | abierta)p(abierta) + P(z | \neg abierta)p(\neg abierta)}$$

$$P(abierta | z) = \frac{0.6 \cdot 0.5}{0.6 \cdot 0.5 + 0.3 \cdot 0.5} = \frac{0.3}{0.3 + 0.15} = 0.67$$

- $z$  eleva la probabilidad que la puerta esté abierta

# Combinando evidencia

- Supongamos que el robot obtiene una segunda medición  $z_2$
- Cómo podemos incorporar esta nueva información?
- En general, cómo podemos estimar  $P(x / z_1, \dots, z_n)$ ?

# Actualización Recursiva Bayesiana

$$P(x \mid z_1, \dots, z_n) = \frac{P(z_n \mid x, z_1, \dots, z_{n-1})P(x \mid z_1, \dots, z_{n-1})}{P(z_n \mid z_1, \dots, z_{n-1})}$$

## Suposición de Markov:

$z_n$  es independiente de  $z_1, \dots, z_{n-1}$  si conocemos  $x$

$$\begin{aligned} P(x \mid z_1, \dots, z_n) &= \frac{P(z_n \mid x)P(x \mid z_1, \dots, z_{n-1})}{P(z_n \mid z_1, \dots, z_{n-1})} \\ &= \eta P(z_n \mid x)P(x \mid z_1, \dots, z_{n-1}) \\ &= \eta_{1\dots n} \left[ \prod_{i=1\dots n} P(z_i \mid x) \right] P(x) \end{aligned}$$

# Ejemplo: Segunda Medición

- $P(z_2/abierta) = 0.25$                        $P(z_2/\neg abierta) = 0.3$
- $P(abierta/z_1)=2/3$

$$\begin{aligned} P(abierta | z_2, z_1) &= \frac{P(z_2 | abierta)P(abierta | z_1)}{P(z_2 | abierta)P(abierta | z_1) + P(z_2 | \neg abierta)P(\neg abierto | z_1)} \\ &= \frac{\frac{1}{4} \cdot \frac{2}{3}}{\frac{1}{4} \cdot \frac{2}{3} + \frac{3}{10} \cdot \frac{1}{3}} = \frac{\frac{1}{6}}{\frac{1}{6} + \frac{1}{10}} = \frac{\frac{1}{6}}{\frac{4}{15}} = \frac{5}{8} = 0.625 \end{aligned}$$

- $z_2$  disminuye la probabilidad que la puerta este abierta

# Acciones

- En general el mundo es **dinámico** debido a:
  - **Acciones realizadas por el robot,**
  - **Acciones realizadas por otros agentes,**
  - O el simple paso del **tiempo** que produce cambios en el mundo
- Cómo podemos **incorporar** estas **acciones**?

# Acciones más comunes

- El robot **gira sus ruedas** para moverse
- El robot **usa su manipulador** para agarrar un objeto
- El entorno cambia con el **tiempo** ...
  
- Las acciones **nunca suceden con absoluta certeza**
- En contraste con las mediciones, las **acciones en general incrementan la incerteza**

# Modelado de acciones


- Para incorporar el resultado de una acción ***u*** al “belief” actual, usamos la función de densidad de probabilidad condicional

$$P(x / u, x')$$

- Este término especifica la densidad de prob. según la cual ***ejecutando u, el estado cambia de  $x'$  a  $x$ .***




# Ejemplo: Cerrar una puerta



# Transiciones de estado

$P(x \mid u, x')$  para  $u = \text{“cerrar puerta”}$ :



Si la puerta esta abierta, la acción “cerrar puerta” tiene éxito el 90% de las veces

# Integrando el resultado de acciones

Caso continuo:

$$P(x | u) = \int P(x | u, x') P(x') dx'$$

Caso discreto:

$$P(x | u) = \sum P(x | u, x') P(x')$$

Haremos una suposición de independencia para eliminar la  $u$  en el segundo factor de la suma.

## Ejemplo: El *Belief* resultante

$$P(cerrado|u) = \sum P(cerrado|u, x')P(x')$$

$$P(abierto|u) = \sum P(abierto|u, x')P(x')$$

## Ejemplo: El *Belief* resultante

$$\begin{aligned}P(\text{cerrado} \mid u) &= \sum P(\text{cerrado} \mid u, x')P(x') \\&= P(\text{cerrado} \mid u, \text{abierto})P(\text{abierto}) \\&\quad + P(\text{cerrado} \mid u, \text{cerrado})P(\text{cerrado}) \\&= \frac{9}{10} * \frac{5}{8} + \frac{1}{1} * \frac{3}{8} = \frac{15}{16}\end{aligned}$$

$$\begin{aligned}P(\text{abierto} \mid u) &= \sum P(\text{abierto} \mid u, x')P(x') \\&= P(\text{abierto} \mid u, \text{abierto})P(\text{abierto}) \\&\quad + P(\text{abierto} \mid u, \text{cerrado})P(\text{cerrado}) \\&= \frac{1}{10} * \frac{5}{8} + \frac{0}{1} * \frac{3}{8} = \frac{1}{16} \\&= 1 - P(\text{cerrado} \mid u)\end{aligned}$$