Robótica Móvil un enfoque probabilístico

Filtro de Bayes - Filtro de Kalman

Ignacio Mas

Repaso de filtro de Bayes

$$Bel(x_{t}) = \eta p(z_{t} | x_{t}) \int p(x_{t} | u_{t}, x_{t-1}) Bel(x_{t-1}) dx_{t-1}$$

Predicción

$$\overline{Bel}(x_t) = \int p(x_t | u_t, x_{t-1}) Bel(x_{t-1}) dx_{t-1}$$

Corrección

$$Bel(x_t) = \eta p(z_t \mid x_t) \overline{Bel}(x_t)$$

Repaso de filtro de Bayes

$$Bel(x_t) = \eta \ P(z_t \mid x_t) \int P(x_t \mid u_t, x_{t-1}) \ Bel(x_{t-1}) \ dx_{t-1}$$

```
Algoritmo Bayes_filter( Bel(x),d ):
2.
      \eta = 0
3.
      If d is a perceptual data item z then
4.
         For all x do
             Bel'(x) = P(z \mid x)Bel(x)
5.
             \eta = \eta + Bel'(x)
6.
7.
         For all x do
             Bel'(x) = \eta^{-1}Bel'(x)
8.
9.
      Else if d is an action data item u then
10.
         For all x do
             Bel'(x) = \int P(x \mid u, x') Bel(x') dx'
11.
12.
      Return Bel'(x)
```

Filtro de Kalman

- Filtro de Bayes con Gaussianas
- Desarrollado a fines de los 1950's
- Filtro de Bayes más utilizado en la práctica
- Usado en economía, pronóstico climático, navegación satelital, robótica, etc.
- El algoritmo del filtro de Kalman es sólo algunas multiplicaciones matriciales!

Gaussianas

$$p(x) \sim N(m, S^2)$$
:

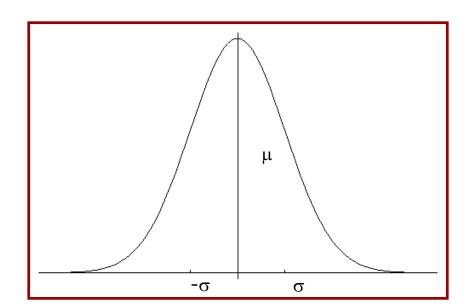
$$p(x) = \frac{1}{\sqrt{2\rho S}} e^{-\frac{1}{2} \frac{(x-m)^2}{S^2}}$$

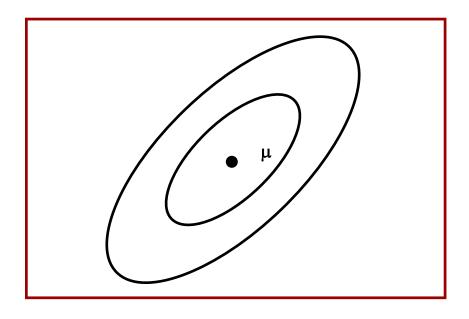
Una variable

$$p(\mathbf{x}) \sim N(m, S)$$
:

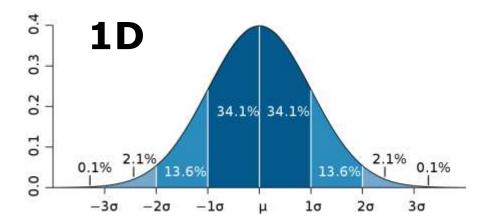
$$p(\mathbf{x}) = \frac{1}{(2\rho)^{d/2} |S|^{1/2}} e^{-\frac{1}{2} (\mathbf{x} - m)^t S^{-1} (\mathbf{x} - m)}$$

Multivariable





Gaussianas



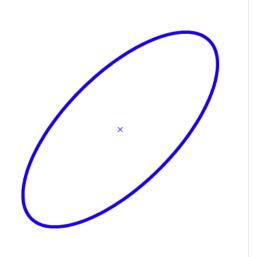
2D

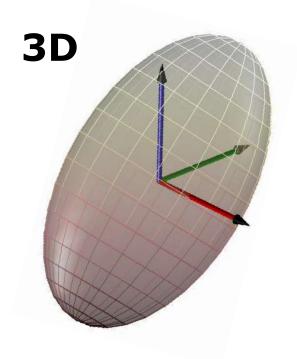
$$C = \begin{bmatrix} 0.020 & 0.013 \\ 0.013 & 0.020 \end{bmatrix}$$

$$\lambda_1 = 0.007$$

$$\lambda_2 = 0.033$$

$$\rho = \sigma_{XY} / \sigma_X \sigma_Y = 0.673$$





Propiedades de Gaussianas

Caso univariable

$$\begin{vmatrix} X \sim N(\mu, \sigma^2) \\ Y = aX + b \end{vmatrix} \Rightarrow Y \sim N(a\mu + b, a^2 \sigma^2)$$

$$\begin{vmatrix} X_1 \sim N(\mu_1, \sigma_1^2) \\ X_2 \sim N(\mu_2, \sigma_2^2) \end{vmatrix} \Rightarrow p(X_1) \cdot p(X_2) \sim N \left(\frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2} \mu_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2} \mu_2, \frac{1}{\sigma_1^{-2} + \sigma_2^{-2}} \right)$$

Propiedades de Gaussianas

Caso multivariable

$$\left| \begin{array}{c} X \sim N(\mu, \Sigma) \\ Y = AX + B \end{array} \right\} \quad \Rightarrow \quad Y \sim N(A\mu + B, A\Sigma A^T)$$

$$\begin{vmatrix} X_1 \sim N(\mu_1, \Sigma_1) \\ X_2 \sim N(\mu_2, \Sigma_2) \end{vmatrix} \Rightarrow p(X_1) \cdot p(X_2) \sim N \left(\frac{\Sigma_2}{\Sigma_1 + \Sigma_2} \mu_1 + \frac{\Sigma_1}{\Sigma_1 + \Sigma_2} \mu_2, \frac{1}{\Sigma_1^{-1} + \Sigma_2^{-1}} \right)$$

(donde la división "-" denota inversión de la matriz)

 Seguirá siendo Gaussiana si empezamos con Gaussianas y hacemos sólo transformaciones afines y productos

Filtro de Kalman Discreto

Estima el estado x de un proceso de tiempo discreto que es gobernado por una ecuación lineal estocástica en diferencias:

$$X_t = A_t X_{t-1} + B_t u_t + C_t$$

con una medición:

$$Z_t = C_t x_t + O_t'$$

Componentes del filtro de Kalman

 A_{t}

Matriz $(n \times n)$ que describe cómo el estado evoluciona de t-1 a t sin control ni ruido.

 B_{t}

Matriz $(n \times l)$ que describe como el control u_t cambia el estado de t-1 a t.

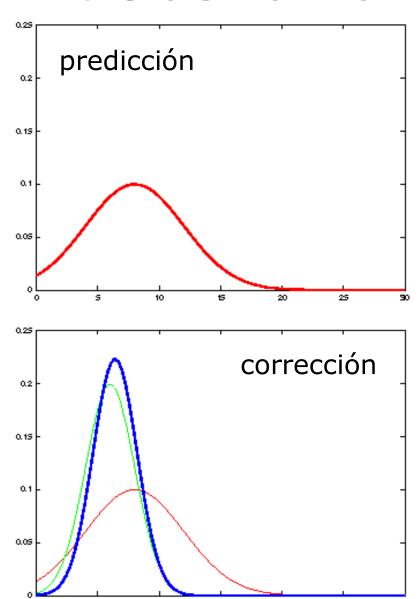
 C_{t}

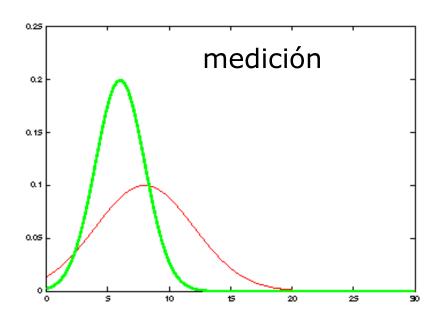
Matriz $(k \times n)$ que describe como mapear el estado x_t a una observación z_t .

 e_{t}

 O_t

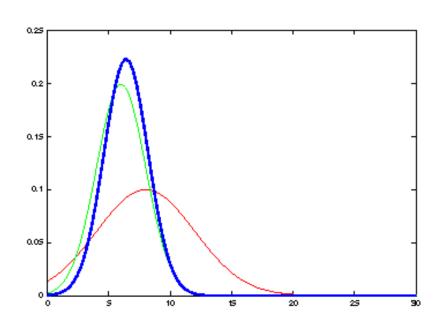
Variables aleatorias que representan el ruido de proceso y de medición que se asumen independientes y normalmente distribuidas con covarianzas Q_t y R_t respectivamente.







Es un promedio ponderado

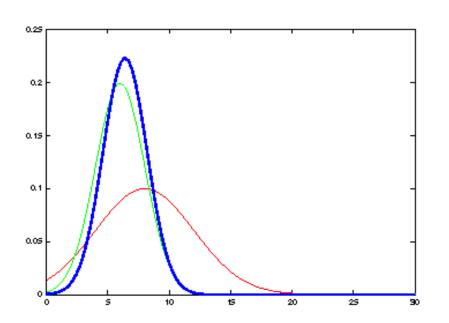


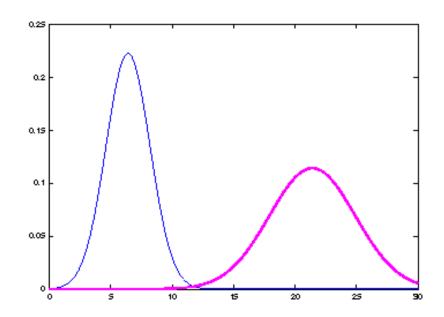
Cómo obtener la curva azul?

Paso de corrección del filtro de Kalman

$$bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t \bar{\mu}_t) \\ \sigma_t^2 = (1 - K_t C_t) \bar{\sigma}_t^2 \end{cases} \quad \text{con} \quad K_t = \frac{\bar{\sigma}_t^2}{\bar{\sigma}_t^2 + \bar{\sigma}_{obs,t}^2}$$

$$bel(x_t) = \begin{cases} \mu_t = \bar{\mu}_t + K_t(z_t - C_t \bar{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \overline{\Sigma}_t \end{cases} \quad \text{con} \quad K_t = \overline{\Sigma}_t C_t^T (C_t \overline{\Sigma}_t C_t^T + R_t)^{-1}$$



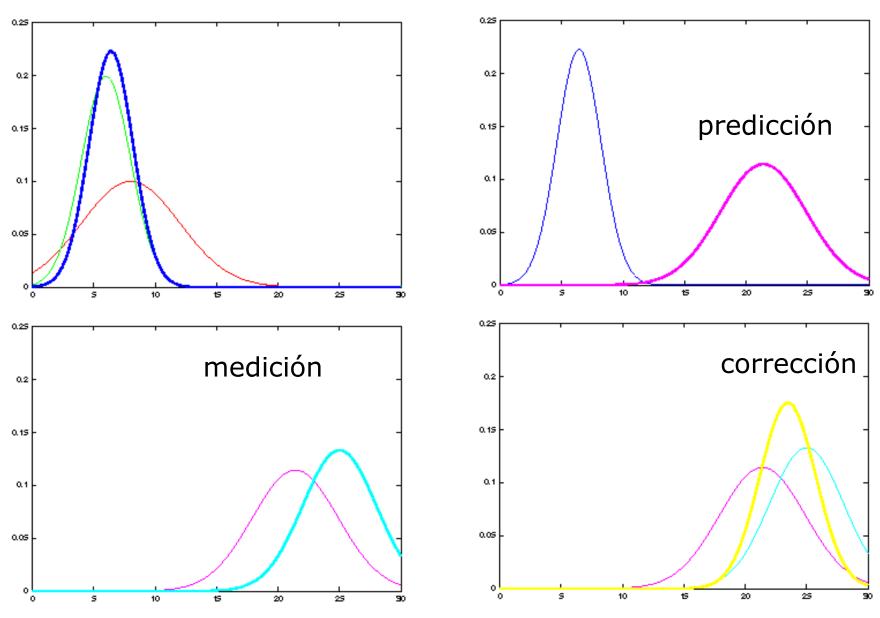


$$\overline{bel}(x_t) = \begin{cases} \overline{\mu}_t = a_t \mu_{t-1} + b_t \mu_t \\ \overline{\sigma}_t^2 = a_t^2 \sigma_t^2 + \sigma_{act,t}^2 \end{cases}$$

$$\overline{bel}(x_t) = \begin{cases} \overline{\mu}_t = A_t \mu_{t-1} + B_t \mu_t \\ \overline{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

Cómo obtener la curva magenta?

Paso de predicción de estado



Sistemas Gaussianos Lineales: Inicialización

El Belief inicial está normalmente distribuido:

$$bel(x_0) = N(x_0; m_0, S_0)$$

Sistemas Gaussianos Lineales: Dinámica

La dinámica son funciones lineales del estado y el control más ruido aditivo:

$$X_t = A_t X_{t-1} + B_t u_t + \mathcal{C}_t$$

$$p(x_{t} | u_{t}, x_{t-1}) = N(x_{t}; A_{t}x_{t-1} + B_{t}u_{t}, Q_{t})$$

$$\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1}) bel(x_{t-1}) dx_{t-1}$$

$$\downarrow \qquad \qquad \downarrow$$

$$\sim N(x_t; A_t x_{t-1} + B_t u_t, Q_t) \sim N(x_{t-1}; \mu_{t-1}, \Sigma_{t-1})$$

Sistemas Gaussianos Lineales: Dinámica

$$\overline{bel}(x_{t}) = \int p(x_{t} \mid u_{t}, x_{t-1}) \qquad bel(x_{t-1}) dx_{t-1}
\downarrow \qquad \qquad \downarrow \qquad \qquad \downarrow
\sim N(x_{t}; A_{t}x_{t-1} + B_{t}u_{t}, Q_{t}) \sim N(x_{t-1}; \mu_{t-1}, \Sigma_{t-1})
\downarrow \qquad \qquad \downarrow
\overline{bel}(x_{t}) = \eta \int \exp \left\{ -\frac{1}{2} (x_{t} - A_{t}x_{t-1} - B_{t}u_{t})^{T} Q_{t}^{-1} (x_{t} - A_{t}x_{t-1} - B_{t}u_{t}) \right\}
\exp \left\{ -\frac{1}{2} (x_{t-1} - \mu_{t-1})^{T} \Sigma_{t-1}^{-1} (x_{t-1} - \mu_{t-1}) \right\} dx_{t-1}
\overline{bel}(x_{t}) = \begin{cases} \overline{\mu}_{t} = A_{t}\mu_{t-1} + B_{t}u_{t} \\ \overline{\Sigma}_{t} = A_{t}\Sigma_{t-1}A_{t}^{T} + Q_{t} \end{cases}$$

Sistemas Gaussianos Lineales: Observaciones

Las observaciones son funciones lineales del estado, más ruido aditivo:

$$Z_t = C_t x_t + O_t$$

$$p(z_t \mid x_t) = N(z_t; C_t x_t, R_t)$$

$$bel(x_t) = \eta \quad p(z_t \mid x_t) \qquad \overline{bel}(x_t)$$

$$\downarrow \qquad \qquad \downarrow$$

$$\sim N(z_t; C_t x_t, R_t) \quad \sim N(x_t; \overline{\mu}_t, \overline{\Sigma}_t)$$

Sistemas Gaussianos Lineales: Observaciones

$$bel(x_{t}) = \eta \quad p(z_{t} \mid x_{t}) \qquad \overline{bel}(x_{t})$$

$$\downarrow \qquad \qquad \downarrow \qquad \qquad \downarrow$$

$$\sim N(z_{t}; C_{t}x_{t}, R_{t}) \quad \sim N(x_{t}; \overline{\mu}_{t}, \overline{\Sigma}_{t})$$

$$\downarrow \qquad \qquad bel(x_{t}) = \eta \exp\left\{-\frac{1}{2}(z_{t} - C_{t}x_{t})^{T} R_{t}^{-1}(z_{t} - C_{t}x_{t})\right\} \exp\left\{-\frac{1}{2}(x_{t} - \overline{\mu}_{t})^{T} \overline{\Sigma}_{t}^{-1}(x_{t} - \overline{\mu}_{t})\right\}$$

$$bel(x_{t}) = \begin{cases} \mu_{t} = \overline{\mu}_{t} + K_{t}(z_{t} - C_{t}\overline{\mu}_{t}) \\ \Sigma_{t} = (I - K_{t}C_{t})\overline{\Sigma}_{t} \end{cases} \quad \text{with} \quad K_{t} = \overline{\Sigma}_{t} C_{t}^{T} (C_{t} \overline{\Sigma}_{t} C_{t}^{T} + R_{t})^{-1}$$

Algoritmo de filtro de Kalman

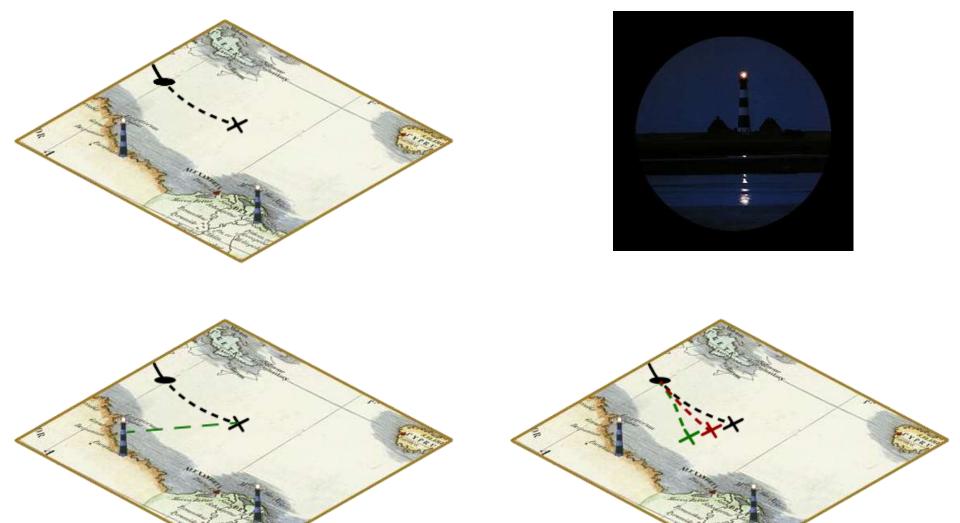
- 1. Algoritmo **Kalman_filter**(μ_{t-1} , Σ_{t-1} , u_t , z_t):
- 2. Predicción:

$$\overline{\mathcal{M}}_{t} = A_{t} \mathcal{M}_{t-1} + B_{t} u_{t}$$

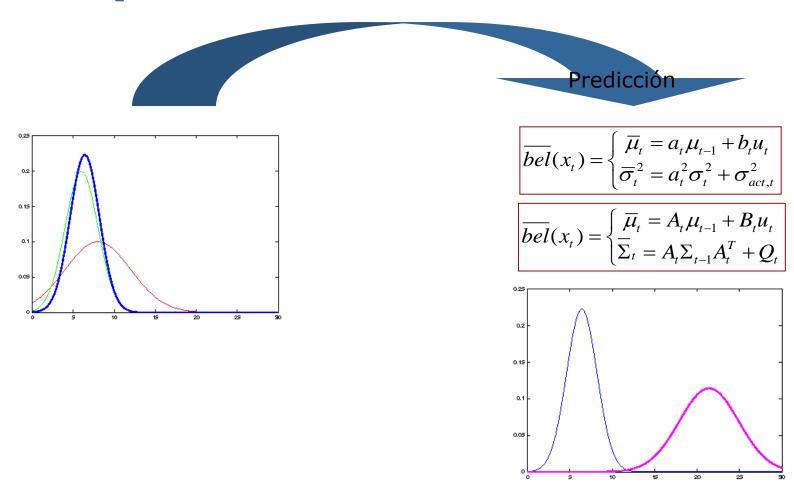
$$\mathbf{4.} \qquad \overline{\mathbf{S}}_t = A_t \mathbf{S}_{t-1} A_t^T + Q_t$$

- 5. Corrección:
- $6. K_t = \overline{S}_t C_t^T (C_t \overline{S}_t C_t^T + R_t)^{-1}$
- $7. M_t = M_t + K_t(z_t C_t M_t)$
- $S_t = (I K_t C_t) \overline{S}_t$
- 9. Return μ_t , Σ_t

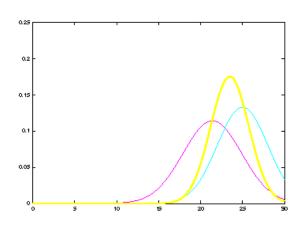
Algoritmo de filtro de Kalman



Ciclo predicción-Corrección

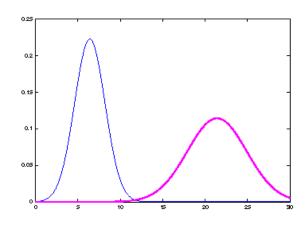


Ciclo predicción-Corrección



$$bel(x_t) = \begin{cases} \mu_t = \overline{\mu}_t + K_t(z_t - \overline{\mu}_t) \\ \sigma_t^2 = (1 - K_t)\overline{\sigma}_t^2 \end{cases}, K_t = \frac{\overline{\sigma}_t^2}{\overline{\sigma}_t^2 + \overline{\sigma}_{obs,t}^2}$$

$$bel(x_t) = \begin{cases} \mu_t = \overline{\mu}_t + K_t(z_t - C_t \overline{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \overline{\Sigma}_t \end{cases}, K_t = \overline{\Sigma}_t C_t^T (C_t \overline{\Sigma}_t C_t^T + R_t)^{-1}$$



Corrección

Ciclo predicción-Corrección



$$bel(x_t) = \begin{cases} \mu_t = \overline{\mu}_t + K_t(z_t - \overline{\mu}_t) \\ \sigma_t^2 = (1 - K_t)\overline{\sigma}_t^2 \end{cases}, K_t = \frac{\overline{\sigma}_t^2}{\overline{\sigma}_t^2 + \overline{\sigma}_{obs,t}^2}$$

$$bel(x_t) = \begin{cases} \mu_t = \overline{\mu}_t + K_t(z_t - C_t \overline{\mu}_t) \\ \Sigma_t = (I - K_t C_t) \overline{\Sigma}_t \end{cases}, K_t = \overline{\Sigma}_t C_t^T (C_t \overline{\Sigma}_t C_t^T + R_t)^{-1}$$

$$\overline{bel}(x_t) = \begin{cases} \overline{\mu}_t = a_t \mu_{t-1} + b_t \mu_t \\ \overline{\sigma}_t^2 = a_t^2 \sigma_t^2 + \sigma_{act,t}^2 \end{cases}$$

$$\overline{bel}(x_t) = \begin{cases} \overline{\mu}_t = A_t \mu_{t-1} + B_t \mu_t \\ \overline{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + Q_t \end{cases}$$

Corrección

Resumen del filtro de Kalman

- Dos parámetros describen el belief del estado del sistema
- Muy eficiente: Polinómico en la dimensión de la medición k y la dimensión del estado n:

$$O(k^{2.376} + n^2)$$

- Óptimo para sistemas Gaussianos lineales!
- Pero: La mayoría de los sistemas robóticos son no-lineales!
- Sólo puede modelar beliefs unimodales