




Robótica Móvil un enfoque probabilístico

Filtro de Bayes– Unscented Kalman Filter (UKF)

Ignacio Mas

KF, EKF



KF, EKF y UKF

- El filtro de Kalman requiere modelos lineales
- EKF linealiza con expansión de Taylor

¿Hay una **mejor** manera de **linearizar**?


Unscented Transform



Unscented Kalman Filter (UKF)

Aproximación de Taylor (EKF)


- Linealización de una función no lineal a través de una expansión de Taylor



Unscented Transform


- Calcular un conjunto de puntos:

Puntos Sigma




Unscented Transform

- Transformar cada punto sigma con la función no lineal



Unscented Transform

- Calcular una Gaussiana con los puntos transformados y pesados



Unscented Transform - Pasos

- Calcular un conjunto de Puntos Sigma
- A cada Punto Sigma se le asocia un peso
- Se transforma cada punto con la función no lineal
- Se calcula una Gaussiana a partir de los puntos pesados
- Se evita linealizar **alrededor de la media**, como en el caso de Taylor (EKF)

Puntos Sigma

- ¿Cómo elegir los Puntos Sigma?
- ¿Cómo calcular sus pesos?
- Seleccionar $\mathcal{X}^{[i]}, w^{[i]}$ tales que:

$$\sum_i w^{[i]} = 1$$

$$\mu = \sum_i w^{[i]} \mathcal{X}^{[i]}$$

$$\Sigma = \sum_i w^{[i]} (\mathcal{X}^{[i]} - \mu)(\mathcal{X}^{[i]} - \mu)^T$$

- No hay una única solución a $\mathcal{X}^{[i]}, w^{[i]}$

Puntos Sigma

- Elección de Puntos Sigma

$$\begin{aligned}\mathcal{X}^{[0]} &= \mu && \text{primer punto: la media} \\ \mathcal{X}^{[i]} &= \mu + \left(\sqrt{(n + \lambda) \Sigma} \right)_i && \text{for } i = 1, \dots, n \\ \mathcal{X}^{[i]} &= \mu - \left(\sqrt{(n + \lambda) \Sigma} \right)_{i-n} && \text{for } i = n + 1, \dots, 2n\end{aligned}$$

Raíz cuadrada de una matriz

dimensionalidad

Parámetro de escala

Vector columna

Raíz cuadrada de una matriz

- Definiendo S como $\Sigma = SS$
- Se calcula diagonalizando

$$\begin{aligned}\Sigma &= VDV^{-1} \\ &= V \begin{pmatrix} d_{11} & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & d_{nn} \end{pmatrix} V^{-1} \\ &= V \begin{pmatrix} \sqrt{d_{11}} & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \sqrt{d_{nn}} \end{pmatrix} \begin{pmatrix} \sqrt{d_{11}} & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \sqrt{d_{nn}} \end{pmatrix} V^{-1}\end{aligned}$$

Raíz cuadrada de una matriz

- Se puede definir

$$S = V \underbrace{\begin{pmatrix} \sqrt{d_{11}} & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \sqrt{d_{nn}} \end{pmatrix}}_{D^{1/2}} V^{-1}$$

- Tal que

$$SS = (VD^{1/2}V^{-1})(VD^{1/2}V^{-1}) = VDV^{-1} = \Sigma$$

Raíz cuadrada de Cholesky de una matriz

- Definición alternativa de raíz cuadrada

$$L \text{ con } \Sigma = LL^T$$


- Resulta de la descomposición de Cholesky
- Numéricamente estable
- Se usa para implementar el UKF
- L y Σ tienen los mismos autovectores

Puntos Sigma y autovectores


- Los Puntos Sigma no necesariamente están en los ejes principales de Σ

$$\mathcal{X}^{[i]} = \mu + \left(\sqrt{(n + \lambda) \Sigma} \right)_i \quad \text{for } i = 1, \dots, n$$

$$\mathcal{X}^{[i]} = \mu - \left(\sqrt{(n + \lambda) \Sigma} \right)_{i-n} \quad \text{for } i = n + 1, \dots, 2n$$



Puntos Sigma: Ejemplo



Pesos de los Puntos Sigma

**Cálculo para
la media**

$$w_m^{[i]} = w_c^{[i]}$$

**Cálculo para
la covarianza**

parámetros

$$\begin{aligned} &= \frac{\lambda}{n + \lambda} \\ &= w_m^{[0]} + (1 - \alpha^2 + \beta) \\ &= \frac{1}{2(n + \lambda)} \quad \text{for } i = 1, \dots, 2n \end{aligned}$$

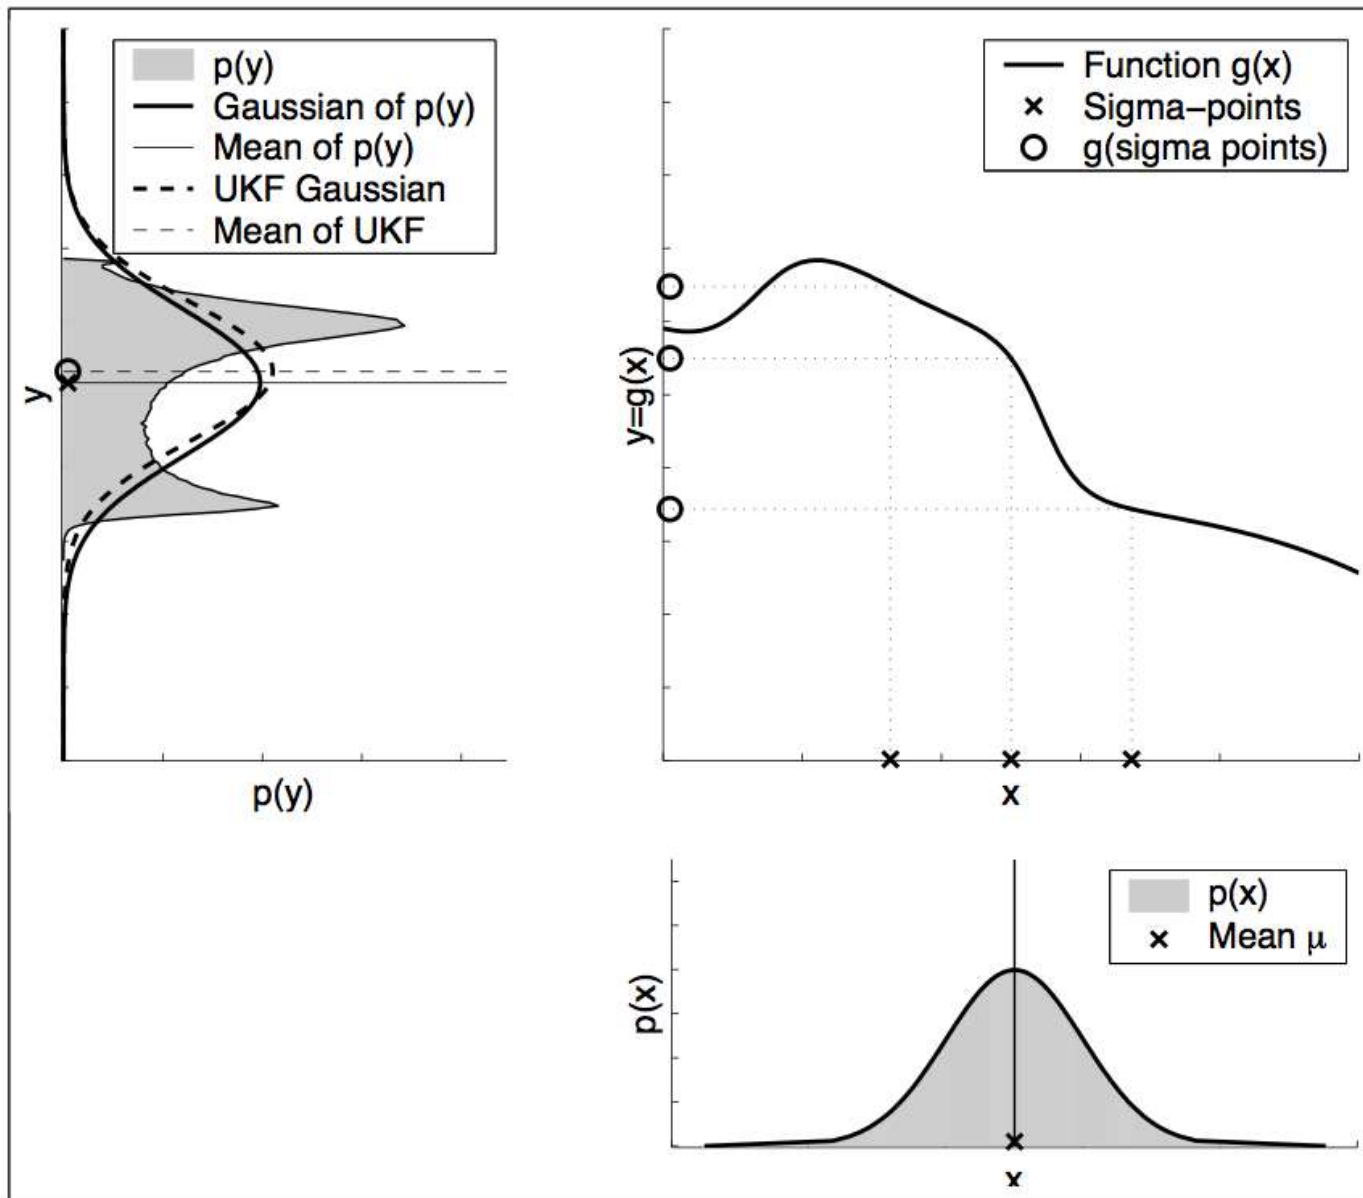
Recuperar la Gaussiana

- Calcular una Gaussiana de los **puntos transformados** y sus pesos



$$\mu' = \sum_{i=0}^{2n} w_m^{[i]} g(\mathcal{X}^{[i]})$$

$$\Sigma' = \sum_{i=0}^{2n} w_c^{[i]} (g(\mathcal{X}^{[i]}) - \mu')(g(\mathcal{X}^{[i]}) - \mu')^T$$

Ejemplo



Ejemplos



$$g((x, y)^T) = \begin{pmatrix} x + 1 \\ y + 1 \end{pmatrix}^T$$

$$g((x, y)^T) = \begin{pmatrix} 1 + x + \sin(2x) + \cos(y) \\ 2 + 0.2y \end{pmatrix}^T$$

Resumen: Unscented Transform

- Puntos Sigma

$$\mathcal{X}^{[0]} = \mu$$

$$\mathcal{X}^{[i]} = \mu + \left(\sqrt{(n + \lambda) \Sigma} \right)_i \quad \text{for } i = 1, \dots, n$$

$$\mathcal{X}^{[i]} = \mu - \left(\sqrt{(n + \lambda) \Sigma} \right)_{i-n} \quad \text{for } i = n + 1, \dots, 2n$$

- Pesos

$$w_m^{[0]} = \frac{\lambda}{n + \lambda}$$

$$w_c^{[0]} = w_m^{[0]} + (1 - \alpha^2 + \beta)$$

$$w_m^{[i]} = w_c^{[i]} = \frac{1}{2(n + \lambda)} \quad \text{for } i = 1, \dots, 2n$$

Parámetros

- Parámetros libres (no hay solución única)
- Comúnmente se usa:

$$\kappa \geq 0$$

$$\alpha \in (0, 1]$$





$$\lambda = \alpha^2(n + \kappa) - n$$

$$\beta = 2$$





Definen que tan
lejos están los
puntos de la media

Valor óptimo
para Gaussianas

Ejemplos



Ejemplos



Algoritmo EKF

- 1: **Extended_Kalman_filter**($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):
- 2: $\bar{\mu}_t = g(u_t, \mu_{t-1})$
- 3: $\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t$
- 4: $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$
- 5: $\mu_t = \bar{\mu}_t + K_t(z_t - h(\bar{\mu}_t))$
- 6: $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$
- 7: return μ_t, Σ_t

de EKF hacia UKF

Unscented

1: ~~Extended_Kalman_filter~~($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):

2: $\bar{\mu}_t =$ Se reemplaza por la propagación

3: $\bar{\Sigma}_t =$ de movimiento de los Puntos Sigma

4: $K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1}$

5: $\mu_t = \bar{\mu}_t + K_t(z_t - h(\bar{\mu}_t))$

6: $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$

7: *return* μ_t, Σ_t

Algoritmo UKF - Predicción

1: **Unscented_Kalman_filter**($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):

2: $\mathcal{X}_{t-1} = (\mu_{t-1} \quad \mu_{t-1} + \sqrt{(n + \lambda)\Sigma_{t-1}} \quad \mu_{t-1} - \sqrt{(n + \lambda)\Sigma_{t-1}})$

3: $\bar{\mathcal{X}}_t^* = g(u_t, \mathcal{X}_{t-1})$

4: $\bar{\mu}_t = \sum_{i=0}^{2n} w_m^{[i]} \bar{\mathcal{X}}_t^{*[i]}$

5: $\bar{\Sigma}_t = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{X}}_t^{*[i]} - \bar{\mu}_t)(\bar{\mathcal{X}}_t^{*[i]} - \bar{\mu}_t)^T + R_t$

de EKF hacia UKF

Unscented

1: ~~Extended_Kalman_filter~~($\mu_{t-1}, \Sigma_{t-1}, u_t, z_t$):

2: $\bar{\mu}_t$ = Se reemplaza por la propagación

3: $\bar{\Sigma}_t$ = de movimiento de los Puntos Sigma

4: Propagar los Puntos Sigma para la observación esperada y la ganancia del filtro

5: $\mu_t = \bar{\mu}_t + K_t(z_t - h(\bar{\mu}_t))$

6: $\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t$

7: *return* μ_t, Σ_t

Algoritmo UKF – Corrección (1)

$$6: \quad \bar{\mathcal{X}}_t = (\bar{\mu}_t \quad \bar{\mu}_t + \sqrt{(n + \lambda)\bar{\Sigma}_t} \quad \bar{\mu}_t - \sqrt{(n + \lambda)\bar{\Sigma}_t})$$

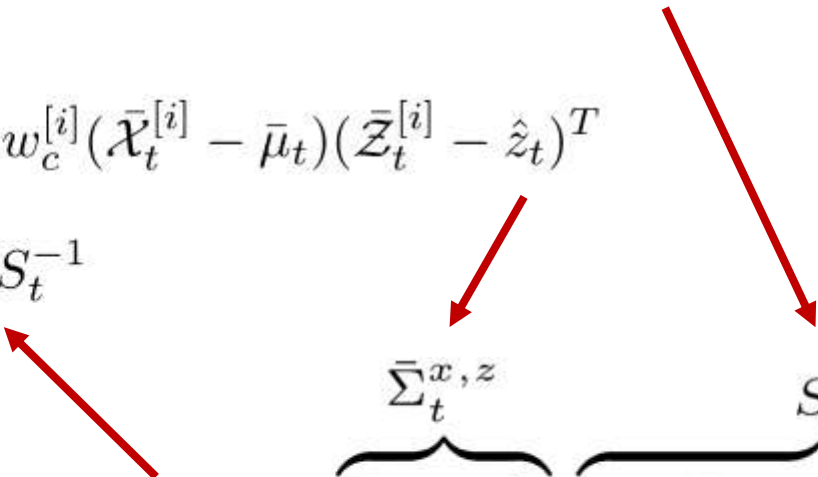
$$7: \quad \bar{\mathcal{Z}}_t = h(\bar{\mathcal{X}}_t)$$

$$8: \quad \hat{z}_t = \sum_{i=0}^{2n} w_m^{[i]} \bar{\mathcal{Z}}_t^{[i]}$$

$$9: \quad S_t = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)(\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)^T + Q_t$$

$$10: \quad \bar{\Sigma}_t^{x,z} = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{X}}_t^{[i]} - \bar{\mu}_t)(\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)^T$$

$$11: \quad K_t = \bar{\Sigma}_t^{x,z} S_t^{-1}$$



$$K_t = \underbrace{\bar{\Sigma}_t^{x,z}}_{\bar{\Sigma}_t} H_t^T (\underbrace{H_t \bar{\Sigma}_t H_t^T + Q_t}_{S_t})^{-1}$$

Algoritmo UKF – Corrección (2)

$$6: \quad \bar{\mathcal{X}}_t = (\bar{\mu}_t \quad \bar{\mu}_t + \sqrt{(n + \lambda)\bar{\Sigma}_t} \quad \bar{\mu}_t - \sqrt{(n + \lambda)\bar{\Sigma}_t})$$

$$7: \quad \bar{\mathcal{Z}}_t = h(\bar{\mathcal{X}}_t)$$

$$8: \quad \hat{z}_t = \sum_{i=0}^{2n} w_m^{[i]} \bar{\mathcal{Z}}_t^{[i]}$$

$$9: \quad S_t = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)(\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)^T + Q_t$$

$$10: \quad \bar{\Sigma}_t^{x,z} = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{X}}_t^{[i]} - \bar{\mu}_t)(\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)^T$$

$$11: \quad K_t = \bar{\Sigma}_t^{x,z} S_t^{-1}$$

$$12: \quad \mu_t = \bar{\mu}_t + K_t(z_t - \hat{z}_t)$$

$$13: \quad \Sigma_t = \bar{\Sigma}_t - K_t S_t K_t^T$$

$$14: \quad \text{return } \mu_t, \Sigma_t$$

Algoritmo UKF – Corrección (2)

$$6: \quad \bar{\mathcal{X}}_t = (\bar{\mu}_t \quad \bar{\mu}_t + \sqrt{(n + \lambda)\bar{\Sigma}_t} \quad \bar{\mu}_t - \sqrt{(n + \lambda)\bar{\Sigma}_t})$$

$$7: \quad \bar{\mathcal{Z}}_t = h(\bar{\mathcal{X}}_t)$$

$$8: \quad \hat{z}_t = \sum_{i=0}^{2n} w_m^{[i]} \bar{\mathcal{Z}}_t^{[i]}$$

$$9: \quad S_t = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)(\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)^T + Q_t$$

$$10: \quad \bar{\Sigma}_t^{x,z} = \sum_{i=0}^{2n} w_c^{[i]} (\bar{\mathcal{X}}_t^{[i]} - \bar{\mu}_t)(\bar{\mathcal{Z}}_t^{[i]} - \hat{z}_t)^T$$

$$11: \quad K_t = \bar{\Sigma}_t^{x,z} S_t^{-1}$$

$$12: \quad \mu_t = \bar{\mu}_t + K_t(z_t - \hat{z}_t)$$

$$13: \quad \Sigma_t = \bar{\Sigma}_t - K_t S_t K_t^T$$


$$14: \quad \text{return } \mu_t, \Sigma_t$$

$$\begin{aligned} \Sigma_t &= (I - K_t H_t) \bar{\Sigma}_t \\ &= \bar{\Sigma}_t - K_t H_t \bar{\Sigma}_t \\ &= \bar{\Sigma}_t - K_t (\Sigma^{x,z})^T \\ &= \bar{\Sigma}_t - K_t (\Sigma^{x,z} s_t^{-1} S_t)^T \\ &= \bar{\Sigma}_t - K_t (K_t S_t)^T \\ &= \bar{\Sigma}_t - K_t S_t^T K_t^T \\ &= \bar{\Sigma}_t - K_t S_t K_t^T \end{aligned}$$


Algoritmo UKF – Covarianza

$$\begin{aligned}\Sigma_t &= (I - K_t H_t) \bar{\Sigma}_t \\ &= \bar{\Sigma}_t - K_t \underbrace{H_t \bar{\Sigma}_t}_{(\bar{\Sigma}^{x,z})^T} \\ &= \bar{\Sigma}_t - K_t (\bar{\Sigma}^{x,z})^T \\ &= \bar{\Sigma}_t - K_t (\underbrace{\bar{\Sigma}^{x,z} S_t^{-1} S_t}_{(K_t S_t)^T})^T \\ &= \bar{\Sigma}_t - K_t (K_t S_t)^T \\ &= \bar{\Sigma}_t - K_t S_t^T K_t^T \\ &= \bar{\Sigma}_t - K_t S_t K_t^T\end{aligned}$$



UKF vs. EKF



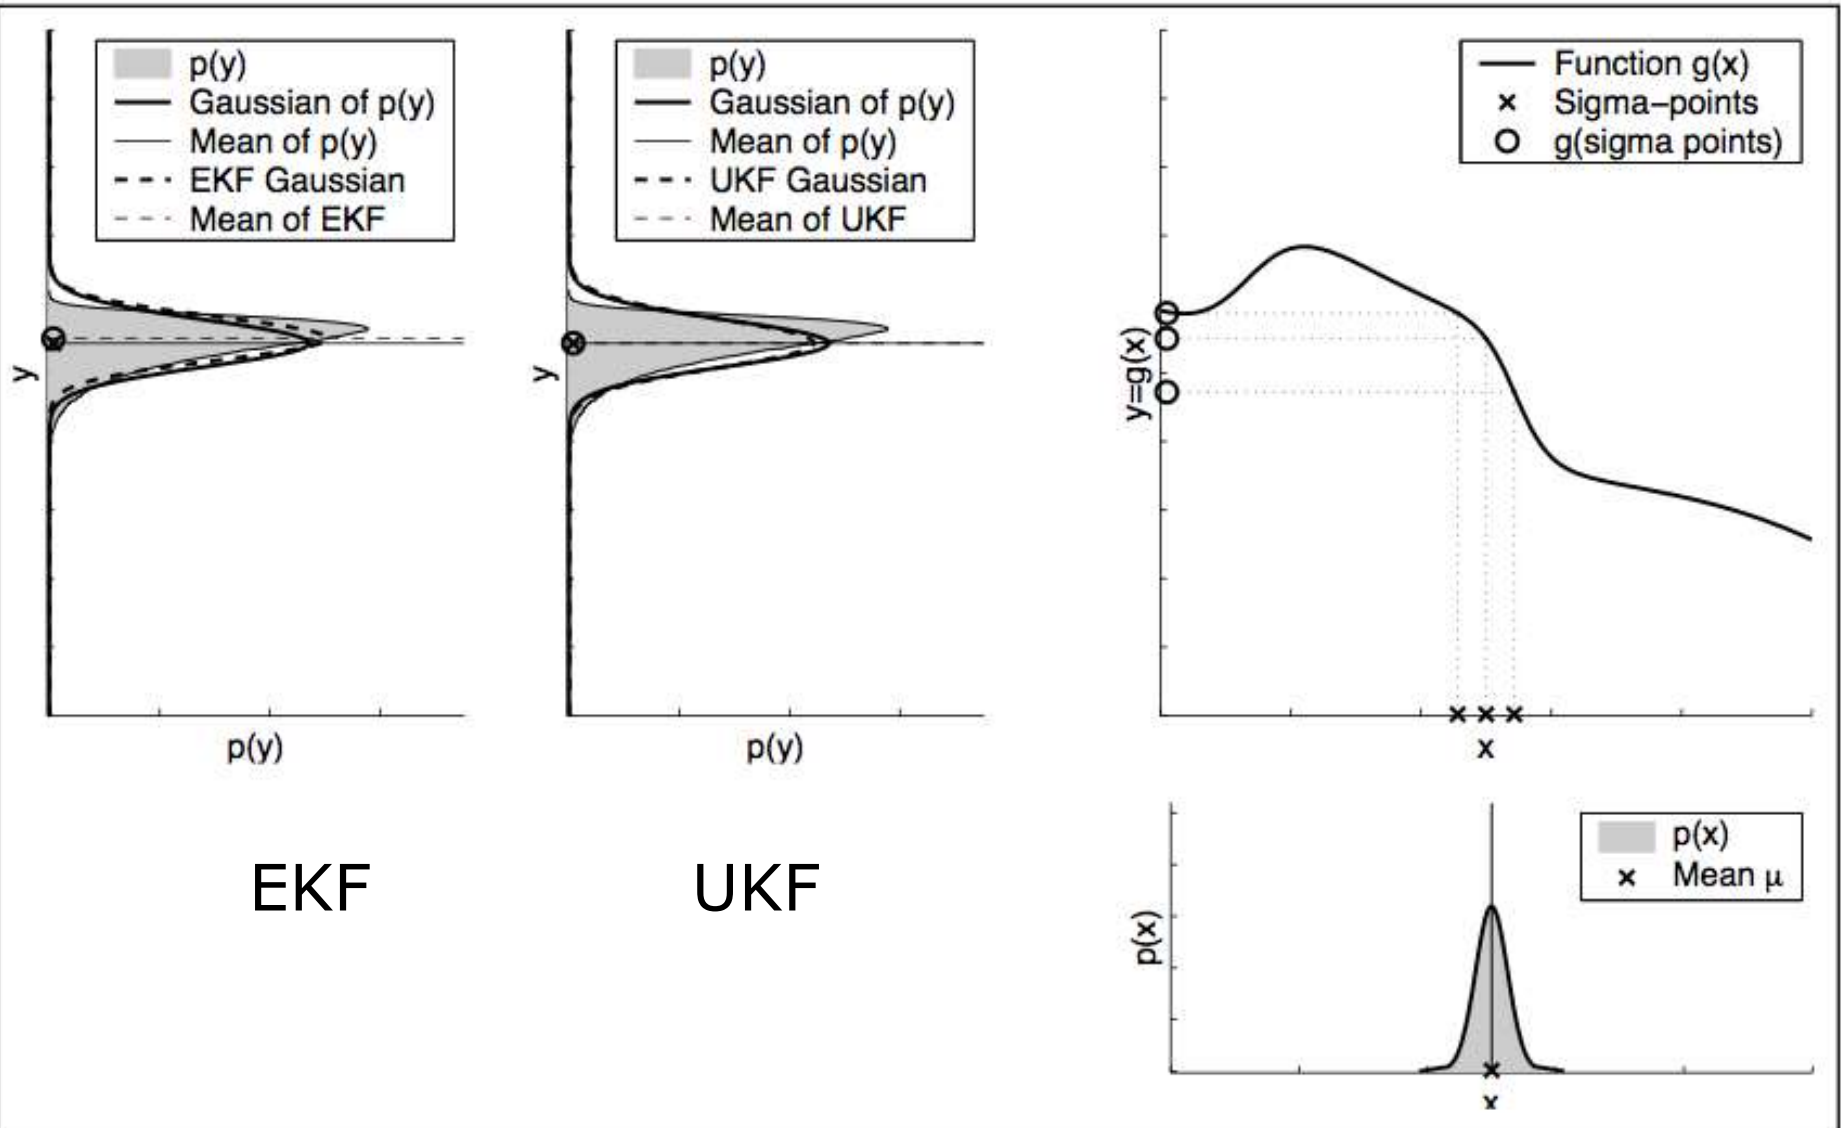
EKF



UKF




UKF vs. EKF (baja covarianza)



UKF vs. EKF (movimiento)




Aproximación EKF




Aproximación UKF

UKF vs. EKF


Actual (sampling)



Linearized (EKF)



UT



Resumen UT y UKF

- UT es una alternativa de linealización
- UT es una mejor aproximación que la expansión de Taylor
- UT usa la propagación de Puntos Sigma
- Existen parámetros libres
- UKF usa UT en los pasos de predicción y corrección

UKF vs EKF

- Resultados iguales para modelos lineales
- UKF aproxima mejor que EKF para modelos no lineales
- En general, las diferencias son pequeñas
- No se necesita calcular Jacobianos
- Mismo orden de complejidad
- UKF es levemente más lento que EKF
- UKF también está restringido a distribuciones Gaussianas