

Robótica Móvil

un enfoque probabilístico


Mapas de grilla y mapeo con poses conocidas

Ignacio Mas

Motivación: ¿Por qué mapas?

- **Aprender mapas** es uno de los problemas fundamentales de la robótica móvil
- Los mapas permiten localización, hacer tareas de manera eficiente, etc.
- Los sistemas **robóticos complejos** se basan en mapas para estas tareas.

El problema general del mapeo



¿Cómo es el entorno en el que estoy?

El problema general del mapeo

- Formalmente, el mapa implica que, dados los **datos**

$$d = \{u_1, z_1, u_2, z_2, \dots, u_t, z_t\}$$

- Se calcula el mapa más probable

$$m^* = \operatorname{argmax}_m P(m \mid d)$$

El problema general del mapeo

- Formalmente, el mapa implica que, dados los **datos**

$$d = \{u_1, z_1, u_2, z_2, \dots, u_t, z_t\}$$

- Se calcula el mapa más probable

$$m^* = \operatorname{argmax}_m P(m \mid d)$$

- Describiremos primero cómo **calcular un mapa dadas las poses del robot**

El problema general del mapeo con poses conocidas



- Formalmente, implica que dadas las **mediciones y las poses**

$$d = \{x_1, z_1, x_2, z_2, \dots, x_t, z_t\}$$

- calcular el mapa más probable

$$m^* = \operatorname{argmax}_m P(m \mid d)$$

Features vs. Mapas Volumétricos




Cortesía de Eduardo Nebot


Mapa de grilla

- Discretizamos el mundo en **celdas**
- La **estructura** de grilla es rígida
- Cada celda puede estar **ocupada o libre**
- Es un modelo no-paramétrico
- Requiere considerable memoria de almacenamiento
- No depende de detección de features

Ejemplo



Ejemplo: FIUBA 1er piso




Representación del mapa

- Suposiciones para simplificar el problema


Suposición 1

- El área que corresponde a una celda está o completamente libre u ocupada



Representación

- Cada celda es una **variable aleatoria binaria** que modela la ocupación




Probabilidad de ocupación

- Cada celda es una **variable aleatoria binaria** que modela la ocupación
- Celda ocupada $p(m_i) = 1$
- Celda no ocupada $p(m_i) = 0$
- Sin información $p(m_i) = 0.5$
- El entorno se asume **estático**

Suposición 2


- Las celdas (las variables aleatorias) son **independientes** unas de otras

No hay dependencia
entre celdas



Representación

- La distribución de probabilidad del mapa está dada por el **producto de las distribuciones** de probabilidad de las celdas individuales

$$p(m) = \prod_i p(m_i)$$



mapa

celda


Representación

- La distribución de probabilidad del mapa está dada por el **producto de las distribuciones** de probabilidad de las celdas individuales

$$p(m) = \prod_i p(m_i)$$



vector de 2x2



4 celdas
independientes


Estimación de un mapa a partir de datos

- Dados los datos de un sensor $z_{1:t}$ y las poses $x_{1:t}$ del sensor, estimar el mapa

$$p(m \mid z_{1:t}, x_{1:t}) = \prod_i p(m_i \mid z_{1:t}, x_{1:t})$$



Variable aleatoria binaria



Filtro de Bayes Binario
(para un estado estático)

Estimación de un mapa a partir de datos

$$p(m \mid z_{1:t}, x_{1:t}) = \prod_i p(m_i \mid z_{1:t}, x_{1:t})$$



Debo resolver esto



$$p(m_i \mid z_{1:t}, x_{1:t})$$

Filtro de Bayes Binario de estado estático

$$p(m_i \mid z_{1:t}, x_{1:t}) \stackrel{\text{Bayes rule}}{=} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t}) p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$$

Filtro de Bayes Binario de estado estático

$$\begin{array}{lcl} p(m_i \mid z_{1:t}, x_{1:t}) & \text{Bayes rule} & \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t}) p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\ & \text{Markov} & \frac{p(z_t \mid m_i, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \end{array}$$

Filtro de Bayes Binario de estado estático

$$\begin{array}{lll} p(m_i \mid z_{1:t}, x_{1:t}) & \text{Bayes rule} & \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t}) p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\ & \text{Markov} & \frac{p(z_t \mid m_i, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\ & & \swarrow \\ p(z_t \mid m_i, x_t) & \text{Bayes rule} & \frac{p(m_i \mid z_t, x_t) p(z_t \mid x_t)}{p(m_i \mid x_t)} \end{array}$$

Filtro de Bayes Binario de estado estático

$$\begin{array}{lll} p(m_i \mid z_{1:t}, x_{1:t}) & \text{Bayes}_{\underline{\underline{\text{rule}}}} & \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t}) p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\ & \text{Markov}_{\underline{\underline{\text{rule}}}} & \frac{p(z_t \mid m_i, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\ & \text{Bayes}_{\underline{\underline{\text{rule}}}} & \frac{p(m_i \mid z_t, x_t) p(z_t \mid x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i \mid x_t) p(z_t \mid z_{1:t-1}, x_{1:t})} \end{array}$$

Filtro de Bayes Binario de estado estático

$p(m_i \mid z_{1:t}, x_{1:t})$	Bayes <u>rule</u>	$\frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t}) p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$
	Markov <u></u>	$\frac{p(z_t \mid m_i, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})}$
	Bayes <u>rule</u>	$\frac{p(m_i \mid z_t, x_t) p(z_t \mid x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i \mid x_t) p(z_t \mid z_{1:t-1}, x_{1:t})}$
	Markov <u></u>	$\frac{p(m_i \mid z_t, x_t) p(z_t \mid x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i) p(z_t \mid z_{1:t-1}, x_{1:t})}$

Filtro de Bayes Binario de estado estático

$$\begin{array}{ll}
 p(m_i \mid z_{1:t}, x_{1:t}) & \text{Bayes rule} \\
 & \underline{\underline{=}} \frac{p(z_t \mid m_i, z_{1:t-1}, x_{1:t}) p(m_i \mid z_{1:t-1}, x_{1:t})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
 & \text{Markov} \\
 & \underline{\underline{=}} \frac{p(z_t \mid m_i, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(z_t \mid z_{1:t-1}, x_{1:t})} \\
 & \text{Bayes rule} \\
 & \underline{\underline{=}} \frac{p(m_i \mid z_t, x_t) p(z_t \mid x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i \mid x_t) p(z_t \mid z_{1:t-1}, x_{1:t})} \\
 & \text{Markov} \\
 & \underline{\underline{=}} \frac{p(m_i \mid z_t, x_t) p(z_t \mid x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i) p(z_t \mid z_{1:t-1}, x_{1:t})}
 \end{array}$$

Luego lo mismo para el evento opuesto:

$$\begin{array}{ll}
 p(\neg m_i \mid z_{1:t}, x_{1:t}) & \text{the same} \\
 & \underline{\underline{=}} \frac{p(\neg m_i \mid z_t, x_t) p(z_t \mid x_t) p(\neg m_i \mid z_{1:t-1}, x_{1:t-1})}{p(\neg m_i) p(z_t \mid z_{1:t-1}, x_{1:t})}
 \end{array}$$

Filtro de Bayes Binario de estado estático

- Del cociente de ambas probabilidades, obtenemos:

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{p(\neg m_i \mid z_{1:t}, x_{1:t})} = \frac{\frac{p(m_i \mid z_t, x_t) \cancel{p(z_t \mid x_t)} p(m_i \mid z_{1:t-1}, x_{1:t-1})}{p(m_i) \cancel{p(z_t \mid z_{1:t-1}, x_{1:t-1})}}}{\frac{p(\neg m_i \mid z_t, x_t) \cancel{p(z_t \mid x_t)} p(\neg m_i \mid z_{1:t-1}, x_{1:t-1})}{p(\neg m_i) \cancel{p(z_t \mid z_{1:t-1}, x_{1:t-1})}}}$$

$$\begin{aligned} & \frac{p(m_i \mid z_{1:t}, x_{1:t})}{p(\neg m_i \mid z_{1:t}, x_{1:t})} \\ &= \frac{p(m_i \mid z_t, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1}) p(\neg m_i)}{p(\neg m_i \mid z_t, x_t) p(\neg m_i \mid z_{1:t-1}, x_{1:t-1}) p(m_i)} \end{aligned}$$

Filtro de Bayes Binario de estado estático

- Del cociente de ambas probabilidades, obtenemos:

$$\begin{aligned} & \frac{p(m_i \mid z_{1:t}, x_{1:t})}{p(\neg m_i \mid z_{1:t}, x_{1:t})} \\ &= \frac{p(m_i \mid z_t, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1}) p(\neg m_i)}{p(\neg m_i \mid z_t, x_t) p(\neg m_i \mid z_{1:t-1}, x_{1:t-1}) p(m_i)} \\ &= \frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)} \frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})} \frac{1 - p(m_i)}{p(m_i)} \end{aligned}$$

Filtro de Bayes Binario de estado estático

- Del cociente de ambas probabilidades, obtenemos:

$$\begin{aligned} & \frac{p(m_i \mid z_{1:t}, x_{1:t})}{1 - p(m_i \mid z_{1:t}, x_{1:t})} \\ &= \frac{p(m_i \mid z_t, x_t) p(m_i \mid z_{1:t-1}, x_{1:t-1}) p(\neg m_i)}{p(\neg m_i \mid z_t, x_t) p(\neg m_i \mid z_{1:t-1}, x_{1:t-1}) p(m_i)} \\ &= \underbrace{\frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)}}_{\text{uses } z_t} \underbrace{\frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})}}_{\text{recursive term}} \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}} \end{aligned}$$

Regla de actualización de ocupación

- Regla recursiva

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{1 - p(m_i \mid z_{1:t}, x_{1:t})} = \underbrace{\frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)}}_{\text{uses } z_t} \underbrace{\frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})}}_{\text{recursive term}} \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}}$$

Notación Log Odds

- El cociente Log Odds se define como

$$l(x) = \log \frac{p(x)}{1 - p(x)}$$

- Pudiéndose recuperar $p(x)$

$$p(x) = \frac{\exp l(x)}{1 + \exp l(x)}$$

Regla de actualización de ocupación

■ Regla recursiva

$$\frac{p(m_i \mid z_{1:t}, x_{1:t})}{1 - p(m_i \mid z_{1:t}, x_{1:t})} = \underbrace{\frac{p(m_i \mid z_t, x_t)}{1 - p(m_i \mid z_t, x_t)}}_{\text{uses } z_t} \underbrace{\frac{p(m_i \mid z_{1:t-1}, x_{1:t-1})}{1 - p(m_i \mid z_{1:t-1}, x_{1:t-1})}}_{\text{recursive term}} \underbrace{\frac{1 - p(m_i)}{p(m_i)}}_{\text{prior}}$$

■ Log Odds:

$$l(m_i \mid z_{1:t}, x_{1:t}) = \underbrace{l(m_i \mid z_t, x_t)}_{\text{inverse sensor model}} + \underbrace{l(m_i \mid z_{1:t-1}, x_{1:t-1})}_{\text{recursive term}} - \underbrace{l(m_i)}_{\text{prior}}$$

Mapas de ocupación en términos Log Odds

- El producto se hace suma

$$\begin{aligned} l(m_i \mid z_{1:t}, x_{1:t}) \\ = \underbrace{l(m_i \mid z_t, x_t)}_{\text{inverse sensor model}} + \underbrace{l(m_i \mid z_{1:t-1}, x_{1:t-1})}_{\text{recursive term}} - \underbrace{l(m_i)}_{\text{prior}} \end{aligned}$$

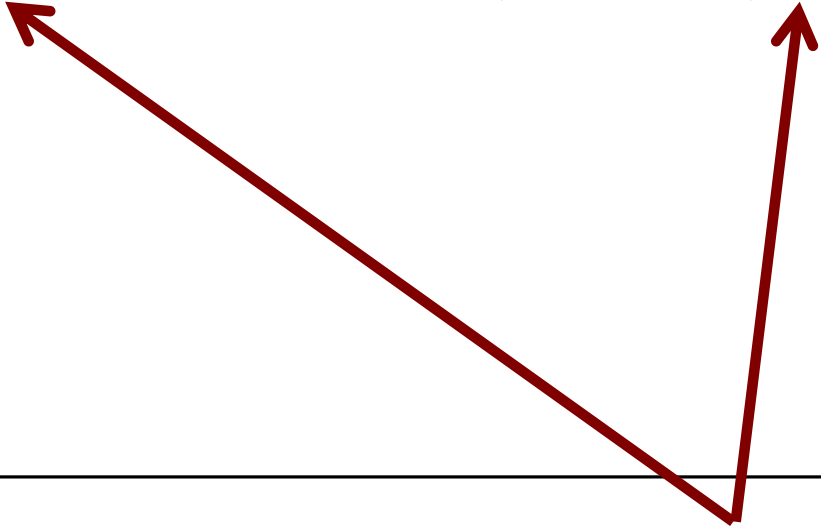
- Que puede escribirse como

$$l_{t,i} = \text{inv_sensor_model}(m_i, x_t, z_t) + l_{t-1,i} - l_0$$

Algoritmo de mapa de Ocupación

occupancy_grid_mapping($\{l_{t-1,i}\}, x_t, z_t$):

```
1:   for all cells  $m_i$  do
2:     if  $m_i$  in perceptual field of  $z_t$  then
3:        $l_{t,i} = l_{t-1,i} + \text{inv\_sensor\_model}(m_i, x_t, z_t) - l_0$ 
4:     else
5:        $l_{t,i} = l_{t-1,i}$ 
6:     endif
7:   endfor
8:   return  $\{l_{t,i}\}$ 
```



Muy eficiente, solo requiere calcular sumas


Mapas de grillas de ocupación

- Desarrollado a mediados de los 80's por Moravec y Elfes
- Originalmente hecho para ultrasonidos muy ruidosos
- También llamado "mapeo con poses conocidas"

Modelo inverso de sensor para Sonar (distancia)


$$l(m_i \mid z_t, x_t) = \text{inv_sensor_model}(m_i, x_t, z_t)$$

Modelo inverso de sensor para Sonar (distancia)




Consideramos las celdas sobre el eje óptico (línea roja)

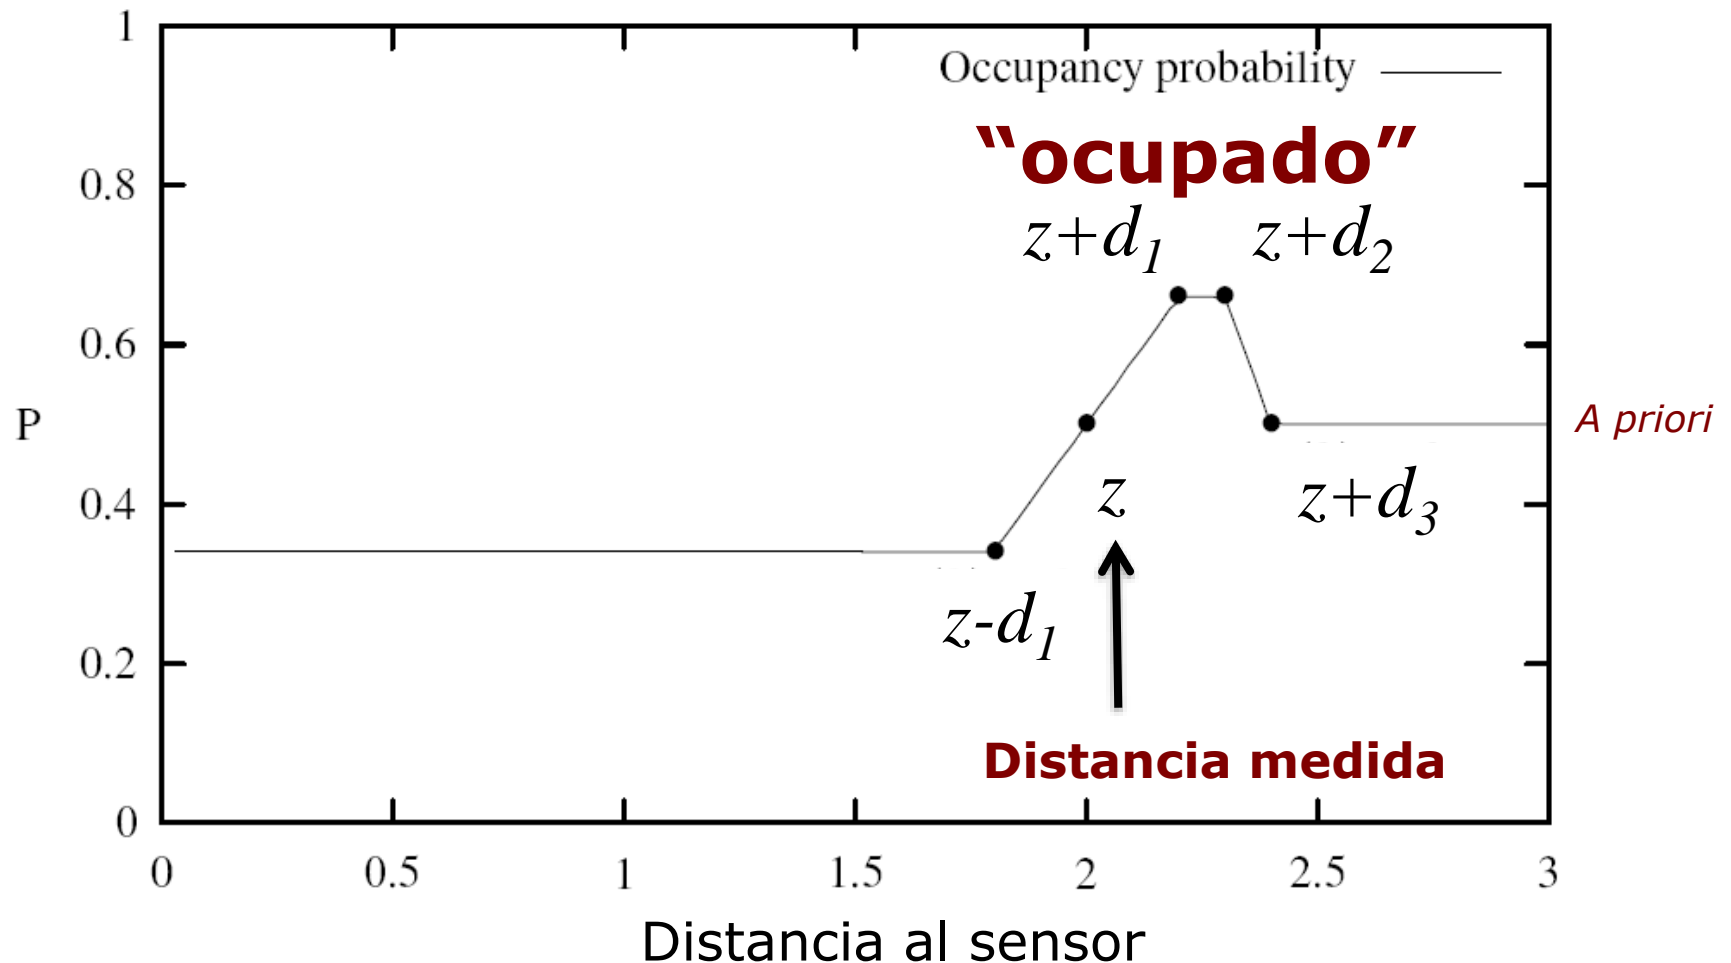
Valor de ocupación según la distancia medida



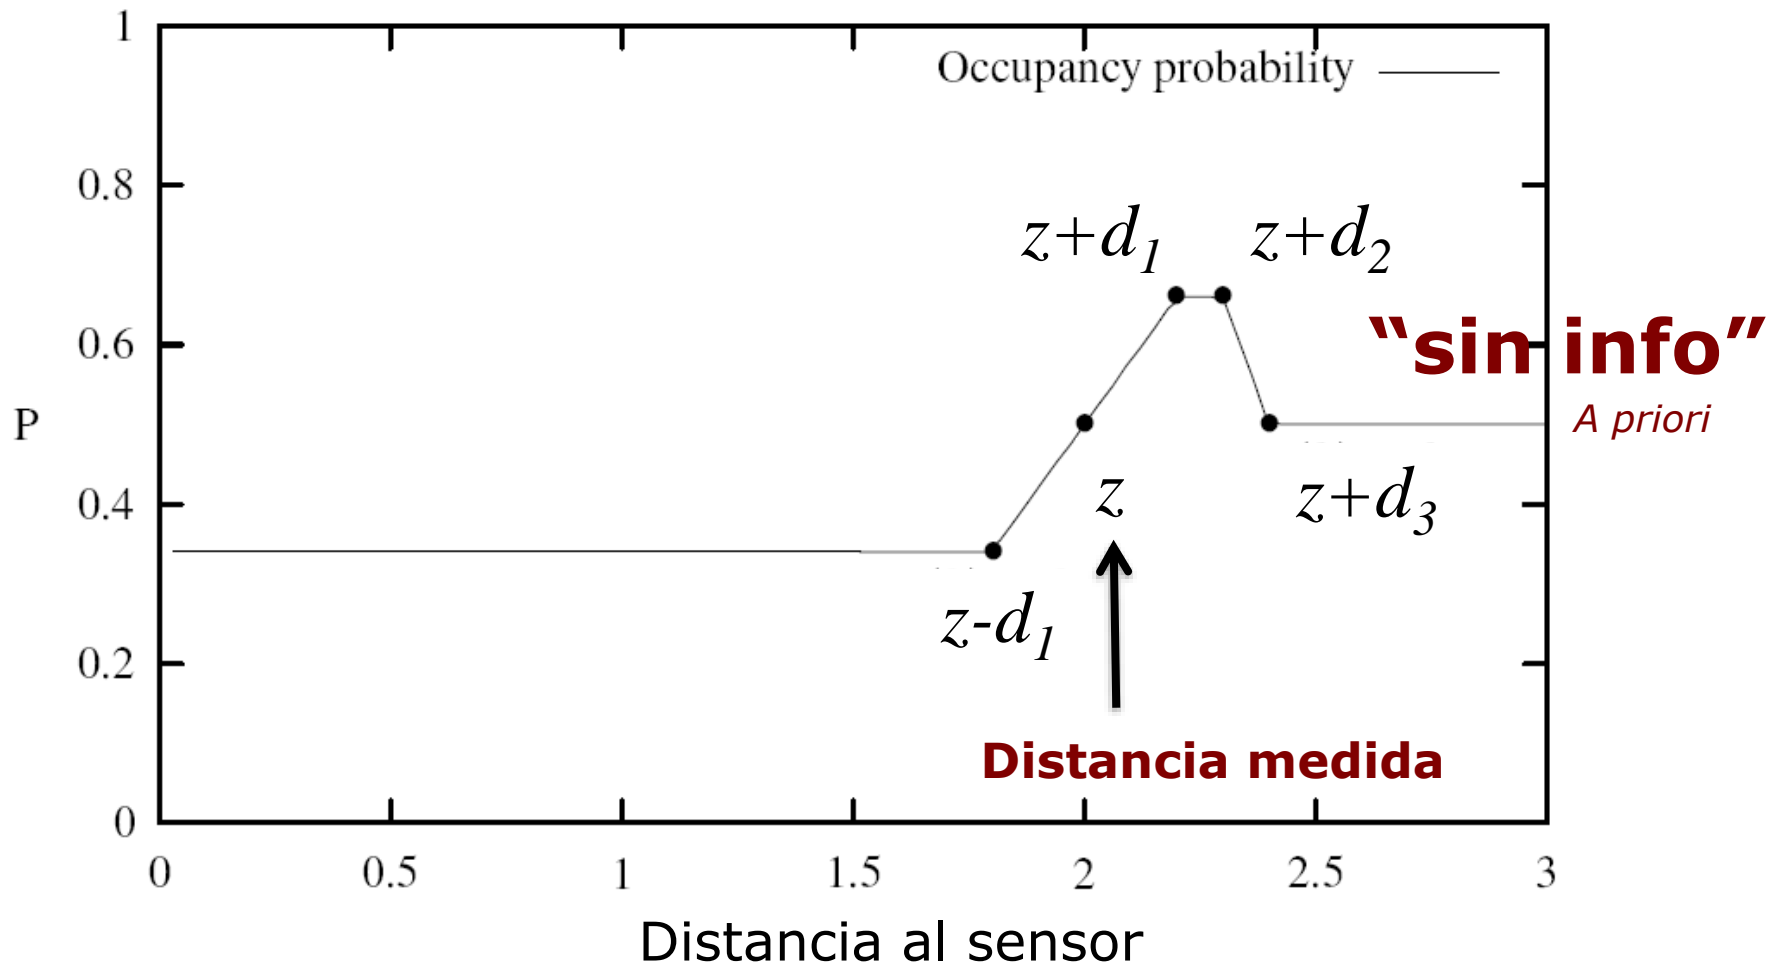
Valor de ocupación según la distancia medida




Valor de ocupación según la distancia medida



Valor de ocupación según la distancia medida




Dependencia con el ángulo de desvío del eje óptico y la distancia




- Lineal en z_t
- Gaussiana en θ

Intensidad de lectura

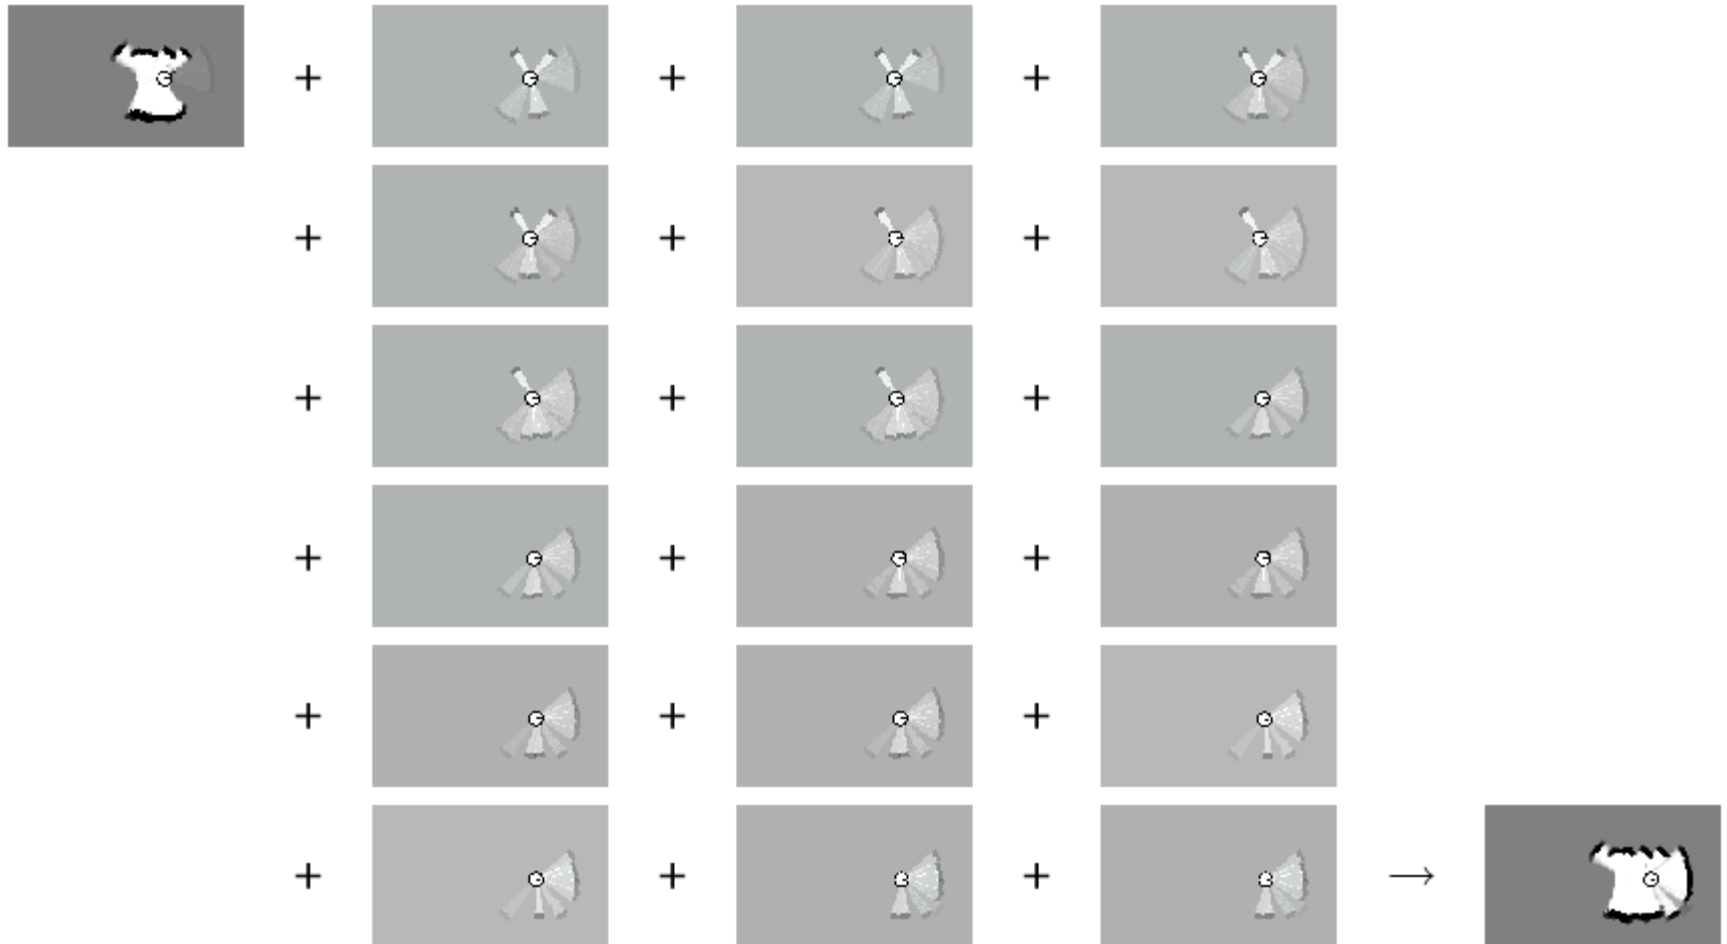
s ———




Modelo resultante $p(m_i \mid z_t, x_t)$





Ejemplo: Actualización incremental de grillas de ocupación



Mapa resultante con sensores de ultrasonido




Ocupación y mapa de Maximum Likelihood





El mapa de maximum likelihood se obtiene redondeando las probabilidades de cada celda a 0 o 1.


Modelo inverso de sensor para Laser Range Finders (LIDAR)




Grilla de ocupación y mapa para LIDARs



Ejemplo: MIT CSAIL, 3^{er} Piso



Univ. de Freiburg, Alemania



Alternativa: Modelo de Conteo


- Para cada celda, contar
 - **hits(x,y)**: número de casos en que el haz terminó en $\langle x,y \rangle$
 - **misses(x,y)**: número de casos en que el haz atravesó $\langle x,y \rangle$

$$Bel(m^{[xy]}) = \frac{\text{hits}(x,y)}{\text{hits}(x,y) + \text{misses}(x,y)}$$

- Valor de interés: $P(\text{reflexión}(x,y))$


El modelo de medición

- Pose en el tiempo t : x_t
- Haz n del escaneo en tiempo t : $z_{t,n}$
- Lectura de rango máximo: $\zeta_{t,n} = 1$
- Haz reflejado por un objeto: $\zeta_{t,n} = 0$



El modelo de medición

- Pose en el tiempo t : x_t
- Haz n del escaneo en tiempo t : $z_{t,n}$
- Lectura de rango máximo: $\zeta_{t,n} = 1$
- Haz reflejado por un objeto: $\zeta_{t,n} = 0$




Rango max: "las primeras $z_{t,n}-1$ celdas atravesadas por el haz deben estar libres"

$$p(z_{t,n}|x_t, m) = \begin{cases} \prod_{k=0}^{z_{t,n}-1} (1 - m_f(x_t, n, k)) & \text{if } \zeta_{t,n} = 1 \\ \dots & \dots \end{cases}$$

El modelo de medición

- Pose en el tiempo t : x_t
- Haz n del escaneo en tiempo t : $z_{t,n}$
- Lectura de rango máximo: $\zeta_{t,n} = 1$
- Haz reflejado por un objeto: $\zeta_{t,n} = 0$



Rango max: "las primeras $z_{t,n}-1$ celdas atravesadas por el haz deben estar libres"

$$p(z_{t,n}|x_t, m) = \begin{cases} \prod_{k=0}^{z_{t,n}-1} (1 - m_f(x_t, n, k)) & \text{if } \zeta_{t,n} = 1 \\ m_f(x_t, n, z_{t,n}) \prod_{k=0}^{z_{t,n}-1} (1 - m_f(x_t, n, k)) & \zeta_{t,n} = 0 \end{cases}$$

sino: "la última celda reflejó el haz, las demás están libres"

Cálculo del mapa más probable

- Calcular valores para m que maximizan
$$m^{\star} = \operatorname{argmax}_m P(m \mid z_1, \dots, z_t, x_1, \dots, x_t)$$
- asumiendo una prob. a priori uniforme para $P(m)$, esto es equivalente a maximizar:

$$\begin{aligned} m^{\star} &= \operatorname{argmax}_m P(z_1, \dots, z_t \mid m, x_1, \dots, x_t) \\ &= \operatorname{argmax}_m \prod_{t=1}^T P(z_t \mid m, x_t) \quad \text{asumo } z_t \text{ independiente} \\ &\quad \text{que solo depende de } x_t \\ &= \operatorname{argmax}_m \sum_{t=1}^T \ln P(z_t \mid m, x_t) \end{aligned}$$

Cálculo del mapa más probable

$$m^{\star} = \operatorname{argmax}_m \sum_{\substack{\text{celdas} \\ j=1}}^J \sum_{\substack{\text{haces} \\ t=1}}^T \sum_{n=1}^N \left(I(f(x_t, n, z_{t,n}) = j) \cdot (1 - \zeta_{t,n}) \cdot \ln m_j \right. \\ \left. + \sum_{k=0}^{z_{t,n}-1} I(f(x_t, n, k) = j) \cdot \ln(1 - m_j) \right)$$

Cálculo del mapa más probable

$$m^{\star} = \operatorname{argmax}_m \sum_{j=1}^J \sum_{t=1}^T \sum_{n=1}^N \overset{\text{"haz } n \text{ termina en celda } j"}{\left(I(f(x_t, n, z_{t,n}) = j) \cdot (1 - \zeta_{t,n}) \cdot \ln m_j \right.}$$
$$\left. + \sum_{k=0}^{z_{t,n}-1} I(f(x_t, n, k) = j) \cdot \ln(1 - m_j) \right)$$

Cálculo del mapa más probable

$$m^{\star} = \operatorname{argmax}_m \sum_{j=1}^J \sum_{t=1}^T \sum_{n=1}^N \overset{\text{"haz } n \text{ termina en celda } j\text{"}}{\left(I(f(x_t, n, z_{t,n}) = j) \cdot (1 - \zeta_{t,n}) \cdot \ln m_j \right)} \\ + \sum_{k=0}^{z_{t,n}-1} I(f(x_t, n, k) = j) \cdot \ln(1 - m_j) \overset{\text{"haz } n \text{ atravesó celda } j\text{"}}{}$$

Cálculo del mapa más probable

$$m^* = \operatorname{argmax}_m \sum_{j=1}^J \sum_{t=1}^T \sum_{n=1}^N \overset{\text{"haz } n \text{ termina en celda } j\text{"}}{\left(I(f(x_t, n, z_{t,n}) = j) \cdot (1 - \zeta_{t,n}) \cdot \ln m_j \right)} \\ + \sum_{k=0}^{z_{t,n}-1} I(f(x_t, n, k) = j) \cdot \ln(1 - m_j) \overset{\text{"haz } n \text{ atravesó celda } j\text{"}}{}$$

Definiendo

$$\alpha_j = \sum_{t=1}^T \sum_{n=1}^N I(f(x_t, n, z_{t,n}) = j) \cdot (1 - \zeta_{t,n})$$

$$\beta_j = \sum_{t=1}^T \sum_{n=1}^N \sum_{k=0}^{z_{t,n}-1} I(f(x_t, n, k) = j)$$

Significado de α_j y β_j

$$\alpha_j = \sum_{t=1}^T \sum_{n=1}^N I(f(x_t, n, z_{t,n}) = j) \cdot (1 - \zeta_{t,n})$$

Corresponde a las veces que un haz que **no es de rango máximo terminó en la celda j** ($hits(j)$)

$$\beta_j = \sum_{t=1}^T \sum_{n=1}^N \sum_{k=0}^{z_{t,n}-1} I(f(x_t, n, k) = j)$$

Corresponde a las veces que un haz **atravesó la celda j sin terminar en ella** ($misses(j)$)

Cálculo del mapa más probable

Entonces, tenemos

$$m^* = \operatorname{argmax}_m \sum_{j=1}^J \left(\alpha_j \ln m_j + \beta_j \ln(1 - m_j) \right)$$

Como los m_j 's son independientes, podemos maximizar esta suma, maximizando para cada j

Si tenemos

$$\frac{\partial}{\partial m_j} = \frac{\alpha_j}{m_j} - \frac{\beta_j}{1-m_j} = 0$$

obtenemos

$$m_j = \frac{\alpha_j}{\alpha_j + \beta_j}$$

El cálculo del mapa más probable se reduce a contar qué tan a menudo una celda refleja una medición y que tan a menudo la celda es atravesada por un haz.

Diferencia entre grillas de ocupación y conteo

- El modelo de conteo determina que tan a menudo una celda refleja un haz.
- El modelo de ocupación representa si una celda está ocupada por un objeto o no.
- Aunque una celda puede estar ocupada por un objeto, la probabilidad de reflexión de ese objeto puede ser muy baja.

Ejemplo de mapa de ocupación



Ejemplo de mapa de reflexión

Paneles de vidrio



Ejemplo

- De un total de n haces, solo 60% se reflejan en una celda y 40% la traspasan.
- Entonces, la prob. de reflexión será 0,60.
- Supongamos $p(occ | z) = 0.55$ cuando un haz termina en una celda y $p(occ | z) = 0.45$ cuando la atraviesa sin terminar en ella.
- Entonces, después de n mediciones, tendremos

$$\left(\frac{0.55}{0.45}\right)^{n*0.6} * \left(\frac{0.45}{0.55}\right)^{n*0.4} = \left(\frac{11}{9}\right)^{n*0.6} * \left(\frac{11}{9}\right)^{-n*0.4} = \left(\frac{11}{9}\right)^{n*0.2}$$

- El mapa de **reflexión** dará un valor de **0.6**, mientras que la **grilla de ocupación** converge a **1** cuando n aumenta.

Resumen (1)

- Los mapas de grillas son un modelo muy usado para representar el entorno
- Las grillas de ocupación **discretizan** el espacio en celdas independientes
- Cada celda es una variable aleatoria **binaria** que estima si la celda está ocupada.
- Estimamos el estado de cada celda usando un filtro de **Bayes binario**.
- Esto permite un **algoritmo eficiente** para el mapeo con poses conocidas
- El modelo “log odds” es rápido de calcular

Resumen (2)

- Los mapas de probabilidad de **reflexión** son una representación **alternativa**
- La idea principal del modelo de sensor es calcular para cada celda la probabilidad de que refleje el haz del sensor
- Dado el modelo del sensor, contar la frecuencia con que el haz intercepta o traspasa una celda da un modelo de maximum likelihood
- Este método tiene un modelo de sensor **similar para mapeo y localización**